

# LLN, CLT, & MLE



Universitas **Al Azhar** Indonesia

Ali Akbar Septiandri

Universitas Al Azhar Indonesia

July 2, 2019

## Ulasan

# Distribusi Gaussian/Normal

---

- Salah satu yang paling sering muncul untuk variabel kontinu
- Berhubungan dengan central limit theorem
- Dituliskan sebagai  $X \sim \mathcal{N}(\mu, \sigma^2)$

# Fakta

---

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

## PDF

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

## Ekspektasi

$$\mathbb{E}[X] = \mu$$

## Variansi

$$\text{Var}[X] = \sigma^2$$

## Law of Large Numbers

## Contoh

---

Anda diberikan koin yang bias dengan peluang munculnya angka adalah 0.55, i.e.  $X \sim Bernoulli(0.55)$ . Hitunglah nilai rata-rata kemunculan A setelah 1 lemparan, 2 lemparan, ..., hingga 2000 lemparan.

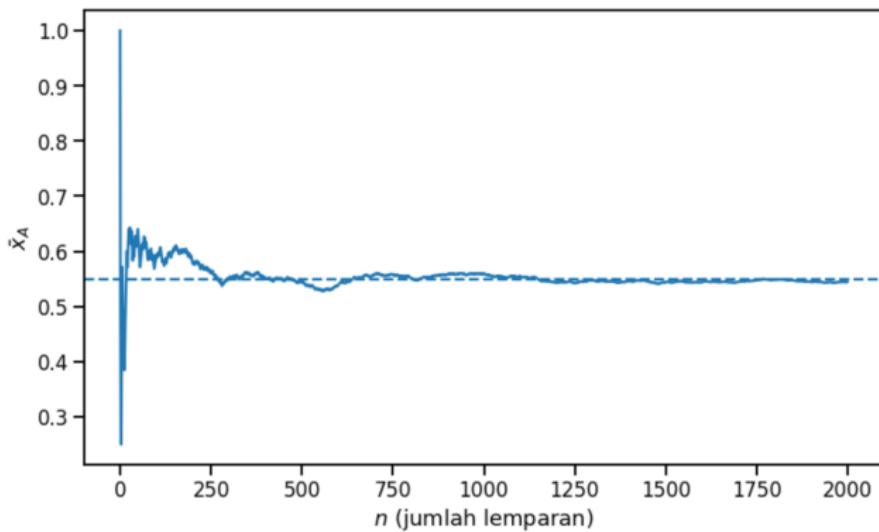
### Ilustrasi

Hasil dari 4 lemparan adalah A G A A. Maka, nilai rata-rata yang Anda dapatkan adalah

- Lemparan 1:  $\bar{x}_A = \frac{1}{1} = 1$ ,
- Lemparan 2:  $\bar{x}_A = \frac{1+0}{2} = 0.5$ ,
- Lemparan 3:  $\bar{x}_A = \frac{1+0+1}{3} = 0.67$ , dan
- Lemparan 4:  $\bar{x}_A = \frac{1+0+1+1}{4} = 0.75$ .

## Ilustrasi

---



Gambar: Nilai rata-rata dari sampel semakin mendekati nilai rata-rata sebenarnya seiring dengan jumlah sampelnya semakin besar

## Law of Large Numbers

---

Nilai **rata-rata dari sampel** (*sample mean*) akan konvergen ke **nilai rata-rata sebenarnya** jika kita menggunakan *cukup banyak* sampel.

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| \geq \epsilon) = 0$$

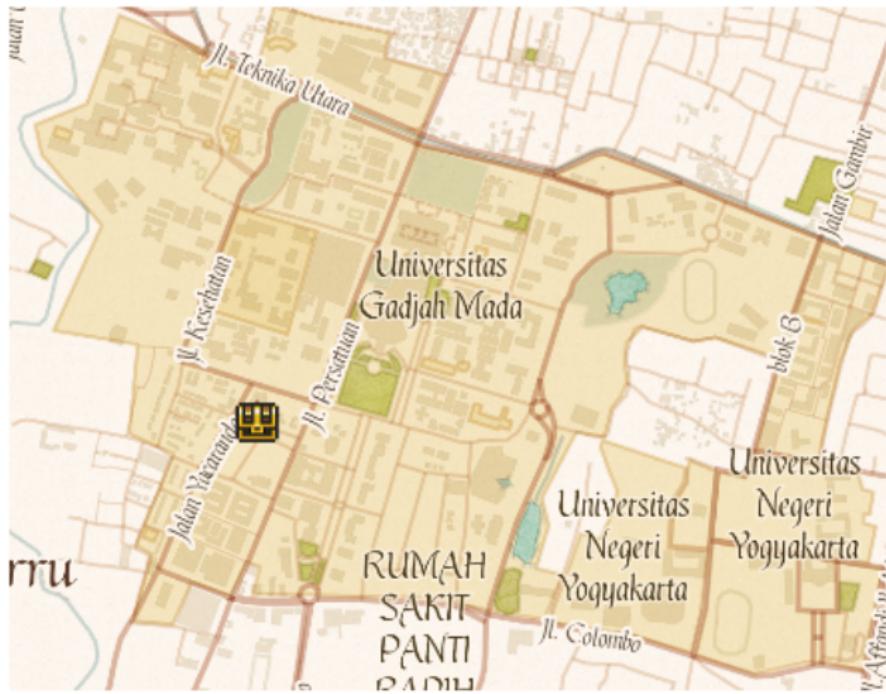
$$P\left(\lim_{n \rightarrow \infty} (\bar{X}) = \mu\right) = 1$$



Mari mencari harta karun!

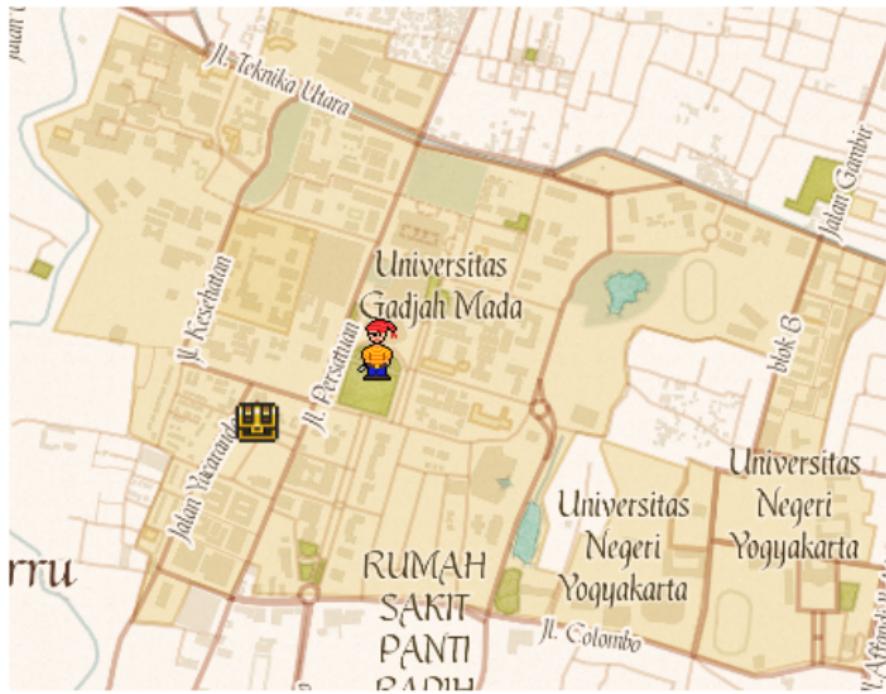
# Mencari Harta Karun

---



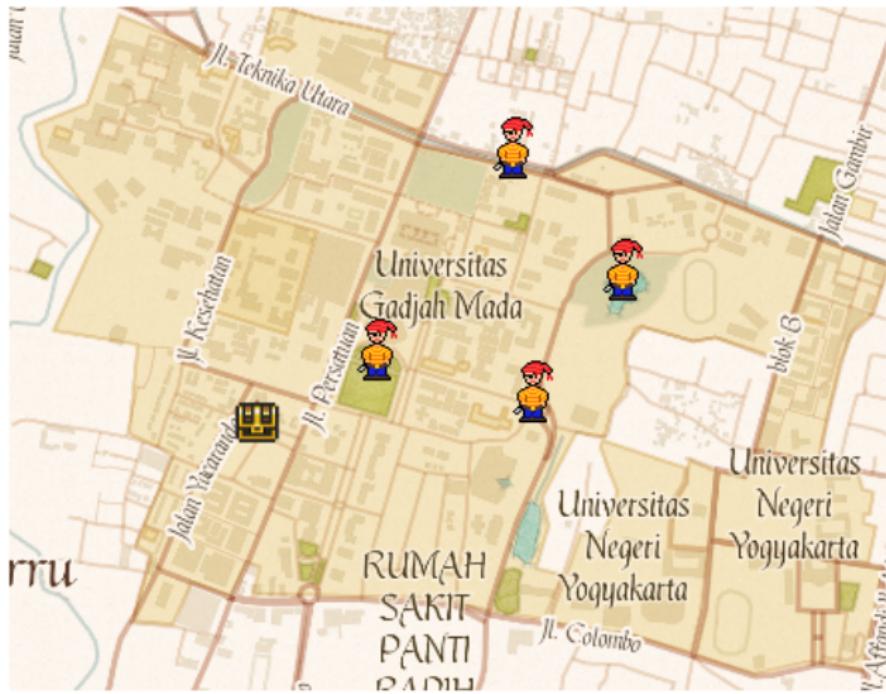
# Mencari Harta Karun

---



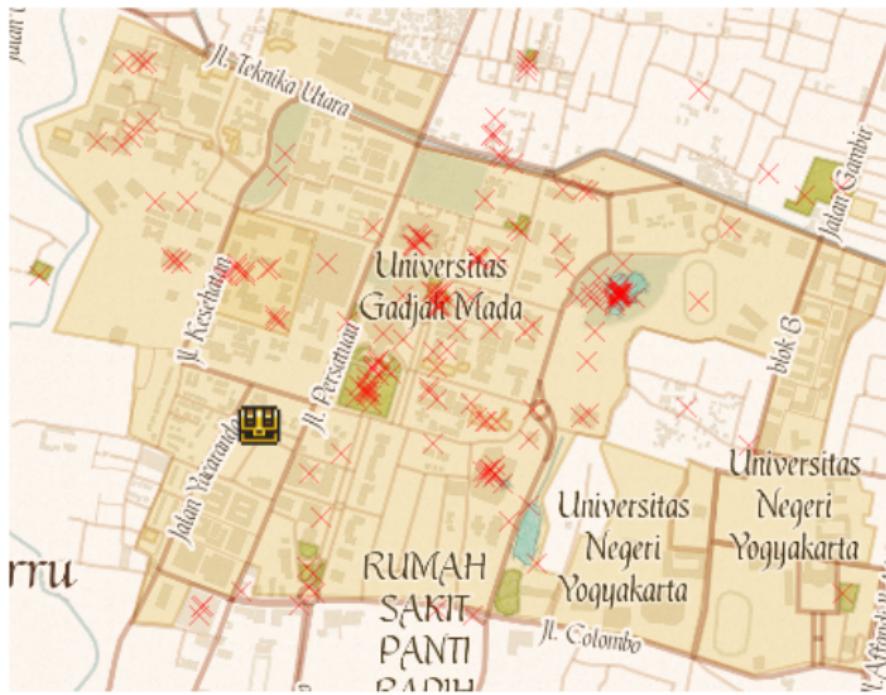
# Mencari Harta Karun

---



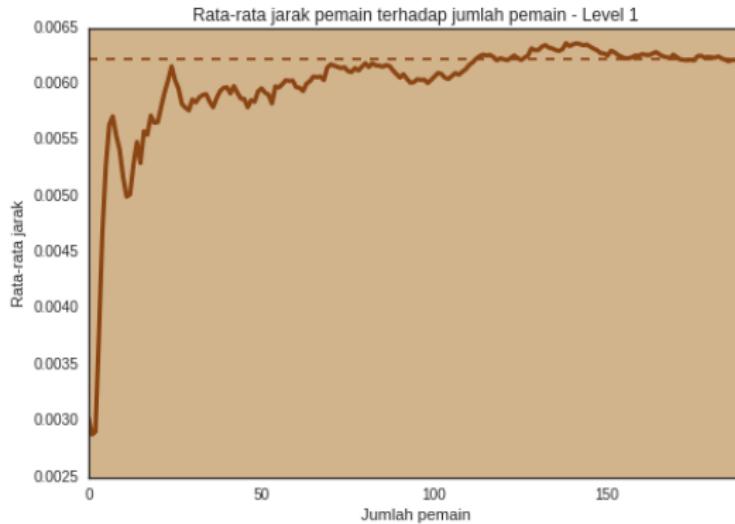
# Mencari Harta Karun

---



# Mencari Harta Karun

---



Gambar: Rata-rata jaraknya juga menjadi konvergen!

## Law of Large Numbers

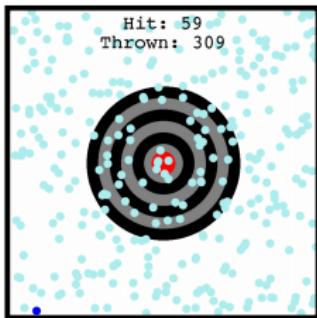
---

Nilai **rata-rata dari sampel** (*sample mean*) akan konvergen ke **nilai rata-rata sebenarnya** jika kita menggunakan *cukup banyak* sampel.

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| \geq \epsilon) = 0$$

$$P\left(\lim_{n \rightarrow \infty} (\bar{X}) = \mu\right) = 1$$

# Frequentist probability and LLN



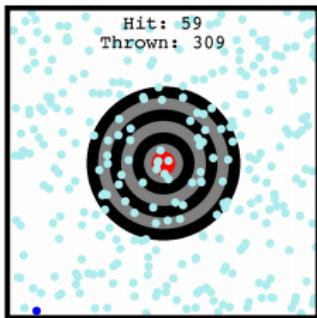
$$P(E) = \lim_{n \rightarrow \infty} \frac{\#(E)}{n}$$

indicator variables  $X_i = \begin{cases} 1 & \text{if } E \text{ occurs on trial } i \\ 0 & \text{otherwise} \end{cases}$

$$\lim_{n \rightarrow \infty} \left( \frac{X_1 + X_2 + \cdots + X_n}{n} \right) = E[X_i]$$

$= \#(E)$

# Frequentist probability and LLN



$$P(E) = \lim_{n \rightarrow \infty} \frac{\#(E)}{n}$$

indicator variables  $X_i = \begin{cases} 1 & \text{if } E \text{ occurs on trial } i \\ 0 & \text{otherwise} \end{cases}$

$$\lim_{n \rightarrow \infty} \left( \frac{X_1 + X_2 + \cdots + X_n}{n} \right) = P(E)$$

# Gambler's fallacy



“I’m due for a win!”

# Dampaknya apa?

## Esensi LLN

---

1. Bagian esensial dari **simulasi, statistik, dan sains**
2. Saat melakukan **eksperimen** untuk mendapatkan data dan **menggeneralisasi hasilnya**, kita menggunakan LLN!

## Central Limit Theorem

Ketika kita melempar koin 10 kali, kita dapat melihat **setiap lemparan** sebagai suatu peubah acak yang mengikuti distribusi Bernoulli dengan  $\theta = 0.5$ , i.e.

$$X_i \sim \text{Bernoulli}(0.5)$$

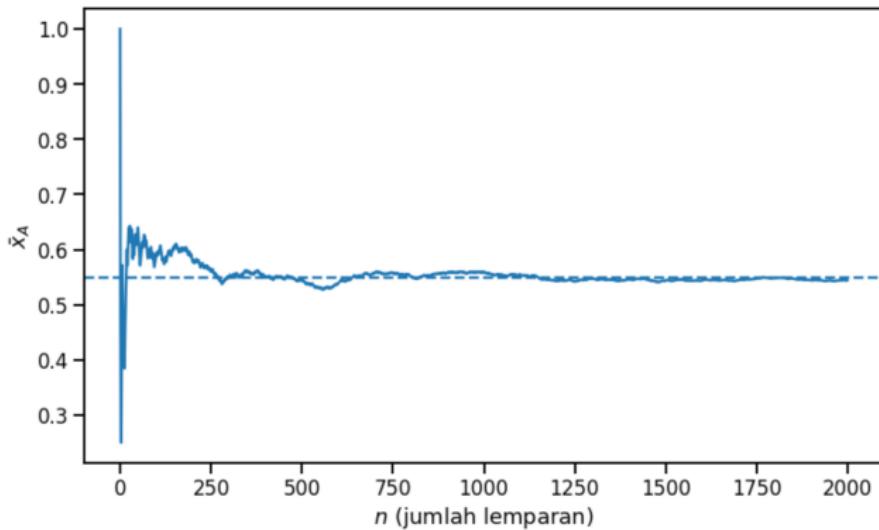
## CLT

*Central limit theorem* menyatakan bahwa **penjumlahan** dan **rata-rata** dari peubah acak IID (*independent and identically distributed*) mengikuti **distribusi normal**. Dengan kata lain,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

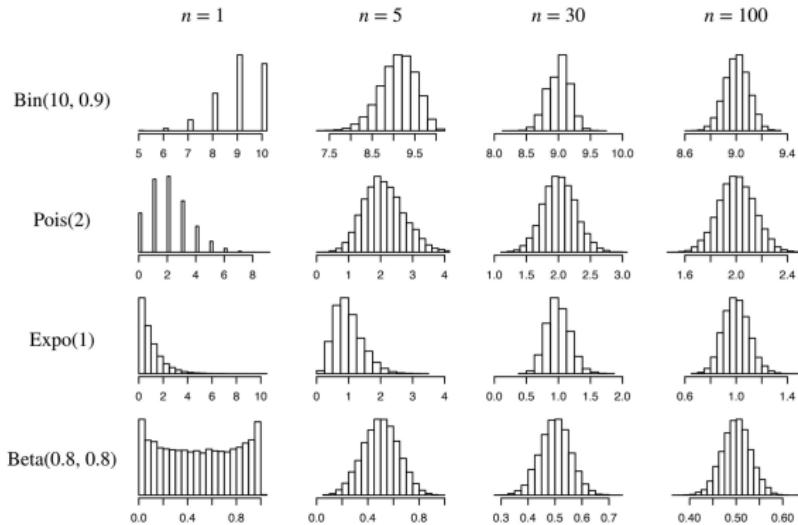
## Ingat!

---



**Gambar:** Distribusi dari rata-rata dari sampel mengikuti distribusi normal

# Generalisasi



**Gambar:** Apapun distribusi awalnya, distribusi dari rata-rata sampel menjadi normal

## Penjumlahan → CLT

---

Asumsikan ada variabel  $Y$  sedemikian sehingga

$$Y = \sum_{i=1}^n X_i$$

Ingat bahwa

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

maka

$$Y = n \cdot \bar{X} \sim \mathcal{N}(n\mu, n\sigma^2)$$

saat  $n \rightarrow \infty$ .

# Contoh

---

## Example

Situs Anda mendapatkan  $W \sim Poi(5/3)$  requests per detik. Server akan *crash* jika mendapatkan 120 atau lebih requests dalam satu menit.

## Solusi 1

Nilai  $\lambda$  dapat kita sesuaikan agar unit waktunya sama, i.e.  $X \sim Poi(\lambda = 60 \cdot 5/3 = 100)$ . Jawabannya dapat dihitung dengan CDF dari Poisson:

$$P(Y \geq 120) = 1 - \sum_{i=0}^{120} \frac{e^{-100}(100)^i}{i!} \approx 0.0282$$

## Contoh

---

Diketahui bahwa  $Poi(\lambda) \approx \mathcal{N}(\lambda, \lambda)$  untuk nilai  $\lambda$  yang besar

### Example

Situs Anda mendapatkan  $W \sim Poi(5/3)$  requests per detik. Server akan *crash* jika mendapatkan 120 atau lebih requests dalam satu menit.

### Solusi 2

Asumsikan  $Y$  adalah jumlah dari 60 RV yang IID dengan  $\mu = \sigma^2 = 5/3$ . Dengan demikian, hampiran untuk  $X$  adalah  $X \approx Y \sim \mathcal{N}(60 \cdot (5/3), 60 \cdot (5/3))$ .

$$\begin{aligned}P(X \geq 120) &\approx P(Y > 119.5) = P\left(\frac{Y - 100}{10} > \frac{119.5 - 100}{10}\right) \\&= P(Z > 1.95) \\&= 1 - \Phi(1.95) \approx 0.0256\end{aligned}$$

## Maximum Likelihood Estimation

## Likelihood

---

- **Asumsi** bahwa suatu peubah acak mengikuti distribusi tertentu

## Likelihood

---

- **Asumsi** bahwa suatu peubah acak mengikuti distribusi tertentu
- Kita punya **data**, tapi **tidak tahu distribusi dan parameter sebenarnya**

# Likelihood

---

- **Asumsi** bahwa suatu peubah acak mengikuti distribusi tertentu
- Kita punya **data**, tapi **tidak tahu distribusi dan parameter sebenarnya**
- Harus *cocokologi*?

## Parameters

---

$$X \sim \begin{cases} Ber(p) & \theta = p \\ Poi(\lambda) & \theta = \lambda \\ Uni(a, b) & \theta = [a, b] \\ \mathcal{N}(\mu, sigma^2) & \theta = [\mu, \sigma^2] \end{cases}$$

## Likelihood

---

$$L(\theta) = P(X_1, \dots, X_n | \theta)$$

Dibaca: Berapa peluang mengobservasi datum pertama **dan** datum kedua **dan** ... **dan** datum ke-n **jika diketahui** bahwa datanya mengikuti distribusi tertentu dengan parameter  $\theta$ .

Karena biasanya  $X_1, X_2, \dots, X_n$  diasumsikan IID, maka dapat ditulis juga sebagai

$$L(\theta) = \prod_{i=1}^n P(X_i | \theta)$$

“Jika diasumsikan bahwa data mengikuti distribusi tertentu, berapa nilai parameter yang dapat memaksimalkan nilai fungsi likelihood-nya.”

- Maximum Likelihood Estimation (MLE)

## Tahapan Mencari MLE

---

1. Definisikan fungsi likelihood

$$L(\theta) = P(X_1, \dots, X_n | \theta)$$

2. Kenakan fungsi log

$$LL(\theta) = \log L(\theta)$$

3. Maksimalkan fungsi ini berdasarkan parameternya

$$\frac{d}{d\theta} LL(\theta) = 0$$

# Maximum likelihood for Bernoulli

The maximum likelihood  $p$  for Bernoulli random variables is the sample mean.



$$\hat{p} = \frac{1}{m} \sum_{i=1}^m X_i$$



# Derivation: MLE for Bernoulli

1. Compute the likelihood.

$$\theta = p$$

$$L(\theta) = P(X_1, \dots, X_m | \theta)$$

$$= \prod_{i=1}^m P(X_i | \theta) \quad \text{don't forget: IID means independent!}$$

$$= \prod_{i=1}^m \begin{cases} p & \text{if } X_i = 1 \\ (1-p) & \text{if } X_i = 0 \end{cases}$$



# Derivation: MLE for Bernoulli

1. Compute the likelihood.

$$\theta = p$$

$$L(\theta) = P(X_1, \dots, X_m | \theta)$$

$$= \prod_{i=1}^m P(X_i | \theta) \quad \text{don't forget: IID means independent!}$$

$$= \prod_{i=1}^m \begin{cases} p & \text{if } X_i = 1 \\ (1-p) & \text{if } X_i = 0 \end{cases}$$

$$= \prod_{i=1}^m p^{X_i} (1-p)^{1-X_i}$$

# Derivation: MLE for Bernoulli

2. Take its log.

$$\theta = p$$

$$L(\theta) = \prod_{i=1}^m \theta^{X_i} (1-\theta)^{1-X_i}$$

$$LL(\theta) = \log \prod_{i=1}^m \theta^{X_i} (1-\theta)^{1-X_i}$$

$$= \sum_{i=1}^m \log [\theta^{X_i} (1-\theta)^{1-X_i}]$$

$$= \sum_{i=1}^m [X_i \log \theta + (1-X_i) \log (1-\theta)]$$

# Derivation: MLE for Bernoulli

3. Maximize this as a function of the parameters.

$$\theta = p$$

$$LL(\theta) = \sum_{i=1}^m [X_i \log \theta + (1 - X_i) \log (1 - \theta)]$$

$$\hat{\theta} = \hat{p} = \arg \max_{\theta} LL(\theta)$$

$$\begin{aligned}\frac{d}{d\theta} LL(\theta) &= \sum_{i=1}^m \left[ \frac{X_i}{\theta} - \frac{1-X_i}{1-\theta} \right] \\ &= \frac{1}{\theta} \sum_{i=1}^m X_i - \frac{1}{1-\theta} \sum_{i=1}^m (1-X_i) \\ &= \left( \frac{1}{\theta} + \frac{1}{1-\theta} \right) \left( \sum_{i=1}^m X_i \right) - \frac{m}{1-\theta} = 0 & \frac{1}{\theta} \left( \sum_{i=1}^m X_i \right) &= m \\ \left( \frac{1-\theta}{\theta} + 1 \right) \left( \sum_{i=1}^m X_i \right) &= m & \theta &= \frac{1}{m} \left( \sum_{i=1}^m X_i \right)\end{aligned}$$

## MLE untuk Normal

---

- Karena distribusi normal menggunakan dua parameter, gunakan **turunan parsial!**
- Hasil akhirnya sangat familiar:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

Coba cek Wikipedia untuk MLE dari berbagai distribusi!

# Terima kasih